Clasificación de Enfermos Diabéticos Mediante Técnicas de Aprendizaje Automático: Regresión Logística, SVM y Random Forest sobre el Dataset Pima Indians

Autor: Alejandro Zakzuk

Tutor: Cristian Rodríguez

Máster en Inteligencia Artificial Aplicada a la Salud

Centro Europeo de Másteres y Posgrados (CEMP)

Fecha: Febrero, 2026

Resumen Ejecutivo

La diabetes mellitus tipo 2 (DM2) es una de las crisis sanitarias más complejas y costosas del siglo XXI y alcanza proporciones epidémicas en todo el mundo. Se estima que casi la mitad de los pacientes permanecen sin diagnosticar durante 4 a 7 años, ya que la enfermedad suele ser asintomática al inicio. Durante este periodo, la hiperglucemia crónica produce daños microvasculares (retinopatía, nefropatía) y macrovasculares (enfermedad cardiovascular) irreversibles. Este problema, unido a la inercia clínica y la saturación de los sistemas de atención primaria, exige la adopción urgente de soluciones tecnológicas para un cribado masivo, eficiente y de bajo coste.

En respuesta a este reto, este Trabajo de Fin de Máster aborda la problemática mediante el diseño y desarrollo de un sistema algorítmico de clasificación supervisada, utilizando el conjunto de datos internacional Pima Indians Diabetes Database (N=768). El análisis de ciencia de datos se enfoca especialmente en la curación de datos y la imputación estadística de valores fisiológicos ausentes, lo que demuestra que la calidad de los datos resulta más determinante que la complejidad del modelo.

Para determinar el mejor enfoque, se han evaluado y comparado tres arquitecturas de aprendizaje automático que representan paradigmas distintos: Regresión Logística (modelo base lineal e interpretable), Máquinas de Vectores de Soporte (SVM con Kernel de Base Radial) y Random Forest (ensamble de árboles de decisión). Los resultados experimentales posicionan al algoritmo Random Forest como la herramienta óptima en el entorno clínico real, con un área bajo la curva ROC (AUC) de 0,942, una sensibilidad del 79,6% y una precisión del 85,7%.

Además de considerar las métricas de rendimiento técnico, este trabajo propone un marco de implementación ético, legal y operativo. A tal fin, se analiza la explicabilidad del modelo (Explainable AI) para garantizar que las decisiones algorítmicas se fundamenten en biomarcadores fisiopatológicamente validados (insulinemia, glucemia, IMC) y no en correlaciones. Asimismo, se detalla el cumplimiento del Reglamento General de Protección de Datos (RGPD) europeo, del EU AI Act para sistemas de alto riesgo y del recientemente aprobado European Health Data Space (EHDS).

Palabras clave: Inteligencia Artificial (IA), Diabetes Mellitus (DM), Machine Learning (aprendizaje automático), Random Forest (técnica de ensemble para clasificación), Soporte a la

Decisión Clínica (CDSS, por sus siglas en inglés), Salud Digital, Cribado Oportunista (detección de enfermedad aprovechando el acceso del paciente a servicios sanitarios por otros motivos), Medicina Preventiva, RGPD (Reglamento General de Protección de Datos), Explicabilidad (capacidad de comprender y justificar las decisiones de los algoritmos).

Índice General

Abreviaturas empleadas

Objetivo del TFM

Capítulo 1: Introducción y contexto epidemiológico

Capítulo 2: Estado del arte y fundamentos teóricos

Capítulo 3: Material y métodos

Capítulo 4: Resultados experimentales

Capítulo 5: Discusión y explicabilidad (XAI)

Capítulo 6: Marco legal, ético y propuesta de despliegue

Conclusiones y recomendaciones futuras

Bibliografía (formato APA 7.ª edición)

Anexos

1. Abreviaturas Empleadas

Abreviatura	Significado
ADA	American Diabetes Association
AGEs	Productos Finales de Glicación Avanzada
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
CDSS	Clinical Decision Support System

CRISP-DM	Cross-Industry Standard Process for Data Mining
DM2	Diabetes Mellitus Tipo 2
DPIA	Data Protection Impact Assessment
EASD	European Association for the Study of Diabetes
EDA	Exploratory Data Analysis
EDPB	European Data Protection Board
EHDS	European Health Data Space
ENT	Enfermedades No Transmisibles
FHIR	Fast Healthcare Interoperability Resources
FN	Falsos Negativos (Error Tipo II)
FP	Falsos Positivos (Error Tipo I)
GDPR/RGPD	General Data Protection Regulation / Reglamento General de Protección de Datos
GLUT4	Transportador de Glucosa Tipo 4
HbA1c	Hemoglobina Glicosilada
HCE	Historia Clínica Electrónica
IA/AI	Inteligencia Artificial
IDF	International Diabetes Federation
IMC/BMI	Índice de Masa Corporal (kg/m²)
ML	Machine Learning (Aprendizaje Automático)
NIDDK	National Institute of Diabetes and Digestive and Kidney Diseases
OMS	Organización Mundial de la Salud

OR	Odds Ratio
RBF	Radial Basis Function
RF	Random Forest (Bosques Aleatorios)
SaMD	Software as a Medical Device
SHAP	SHapley Additive exPlanations
SOG	Sobrecarga Oral de Glucosa
SVM	Support Vector Machines
UKPDS	United Kingdom Prospective Diabetes Study
VN	Verdaderos Negativos
VP	Verdaderos Positivos
VPN	Valor Predictivo Negativo
VPP	Valor Predictivo Positivo
XAI	Explainable Artificial Intelligence

2. Objetivo del TFM

El objetivo primordial de este Trabajo de Fin de Máster es implementar, comparar y evaluar modelos de clasificación basados en técnicas de Inteligencia Artificial supervisada para la detección temprana de pacientes con riesgo de diabetes mellitus tipo 2, utilizando variables clínicas rutinarias y priorizando métricas orientadas al cribado oportunista en el ámbito de la Atención Primaria.

Para alcanzar esta meta general, se han definido los siguientes objetivos específicos y operativos:

Ingeniería y curación de datos de alta fidelidad: establecer un protocolo metodológico estricto para la auditoría de la calidad de los datos médicos. Esto implica detectar inconsistencias lógicas

en los registros (como valores fisiológicos imposibles) y aplicar técnicas de imputación estadística para recuperar la información, lo que demuestra que la calidad del preprocesamiento es más determinante para el éxito clínico que la complejidad del algoritmo elegido.

Evaluación comparativa de arquitecturas de aprendizaje: Implementar y someter a evaluación tres familias distintas de algoritmos de Machine Learning (Modelos Lineales, Máquinas de Vectores de Soporte y Ensambles de Árboles) para determinar empíricamente qué aproximación matemática modela mejor la complejidad no lineal y multifactorial de la fisiopatología metabólica.

Optimización orientada a la seguridad del paciente: calibrar los modelos resultantes sin maximizar la exactitud global (Accuracy), sino priorizando la sensibilidad (Recall). El objetivo ético es minimizar la tasa de falsos negativos, garantizando que el sistema actúe como una red de seguridad efectiva que no deje escapar casos patológicos reales.

Validación de la explicabilidad y transparencia (XAI): Aplicar técnicas de interpretación de modelos, como la importancia de características basada en la impureza de Gini y los valores SHAP (SHapley Additive exPlanations), para verificar que el modelo basa sus predicciones en biomarcadores coherentes con la evidencia médica establecida y no en correlaciones espurias o sesgos de los datos.

3. Capítulo 1: Introducción y Contexto Epidemiológico

3.1. La pandemia de la diabetes: magnitud del problema global

La diabetes mellitus (DM) ha dejado de ser considerada únicamente una patología crónica para ser reconocida por organismos internacionales, como la Organización Mundial de la Salud (OMS) y las Naciones Unidas, como una auténtica emergencia sanitaria global del siglo XXI. Se trata de una de las cuatro enfermedades no transmisibles (ENT) prioritarias a nivel mundial, junto con las enfermedades cardiovasculares, el cáncer y las enfermedades respiratorias crónicas. (International Diabetes Federation [IDF], 2025)

Siguiendo con la dimensión global de la enfermedad, según los datos más recientes de la 11.ª edición del Atlas de la Diabetes de la Federación Internacional de Diabetes (IDF), publicada en febrero de 2025, la prevalencia de la enfermedad ha alcanzado niveles alarmantes. Se estima que

aproximadamente 589 millones de adultos (en el rango de edad de 20 a 79 años) viven actualmente con diabetes en todo el mundo, lo que representa que el 11,1% de los adultos padece la enfermedad. Las proyecciones epidemiológicas no son alentadoras: se espera que esta cifra ascienda a 853 millones para el año 2050, impulsada por mega tendencias demográficas y sociales como el envejecimiento de la población, la urbanización rápida y la adopción global de estilos de vida sedentarios y de dietas hipercalóricas. Un dato particularmente preocupante es que se estima que 252 millones de adultos con diabetes desconocen su condición, lo que equivale al 42,8% del total de casos (IDF, 2025)

Esta creciente prevalencia tiene un fuerte impacto en la mortalidad y los costes sanitarios. La carga de mortalidad es igualmente devastadora: 3,4 millones de personas fallecieron como consecuencia directa de la diabetes en 2024, lo que representa el 9,3% de las muertes globales por todas las causas en la franja de edad de 20 a 79 años. Desde una perspectiva económica, la diabetes impone una carga financiera insostenible que, a nivel global, superó el billón de dólares en 2024, equivalente al 12% del gasto sanitario mundial. La mayor parte de este gasto no se destina al control glucémico (fármacos antidiabéticos o insulina), sino al tratamiento de las complicaciones tardías (diálisis, amputaciones, cirugía cardiovascular, ceguera), que son, en gran medida, prevenibles mediante un diagnóstico precoz (IDF, 2025).

3.2. La diabetes en España: un problema cercano

En el contexto específico de España, los datos del IDF Atlas 2025 indican que la prevalencia total de diabetes mellitus se sitúa alrededor del 14,1% de la población adulta, con aproximadamente 4,66 millones de personas afectadas, cifras que sitúan al país como el quinto de Europa en prevalencia, por detrás de Turquía, Rusia, Alemania e Italia. Además, de acuerdo con los datos de la Sociedad Española de Diabetes (SED), España es el segundo país europeo con mayor prevalencia de la enfermedad entre los estados miembros de la UE (IDF, 2025)

Por otra parte, el dato más preocupante para la salud pública española es que el 35,5% de estos casos permanecen sin diagnosticar, lo que implica que aproximadamente 1,65 millones de personas viven con niveles glucémicos tóxicos sin recibir tratamiento alguno. Estas cifras son coherentes con las reportadas anteriormente por el estudio Di@bet.es, la referencia epidemiológica nacional más sólida, que ya reveló que casi la mitad de los diabéticos desconocía

su condición en el momento del estudio. Este fenómeno, conocido como la regla de las mitades en epidemiología, evidencia una falla sistémica en los mecanismos de detección precoz.

El gasto sanitario asociado a la diabetes en España supera los 6.000 millones de euros anuales y representa entre el 10% y el 15% del presupuesto total de sanidad. Este coste se concentra desproporcionadamente en el tratamiento de las complicaciones crónicas, lo que hace del diagnóstico precoz no solo una prioridad clínica, sino también una necesidad para la sostenibilidad del sistema sanitario público.

3.3. Fisiopatología de la Diabetes Tipo 2: historia natural de la enfermedad

Para comprender la importancia de la inteligencia artificial en este campo, es necesario entender la complejidad biológica de la DM2, que representa entre el 90% y el 95% de los casos de diabetes. A diferencia de la diabetes tipo 1, que es una enfermedad autoinmune de inicio agudo, la DM2 es un trastorno metabólico progresivo y multifactorial caracterizado por dos defectos fisiopatológicos centrales que interactúan entre sí:

La resistencia a la insulina es el defecto primario en la mayoría de los pacientes. (Kahn et al., 2006) Se define como una disminución de la capacidad biológica de los tejidos periféricos sensibles a la insulina (principalmente el músculo esquelético, el tejido adiposo y el hígado) para responder a concentraciones fisiológicas de la hormona. A nivel molecular, esto se traduce en una translocación defectuosa de los transportadores de glucosa (GLUT4) a la membrana celular, lo que impide la captación de glucosa en la sangre. Esta resistencia está fuertemente ligada a la obesidad visceral y a la liberación de ácidos grasos libres y de citoquinas proinflamatorias (TNF-α, IL-6, resistina), que interfieren con la cascada de señalización del receptor de insulina (IRS-1/PI3K/Akt). (Kahn et al., 2006)

Disfunción progresiva de la célula beta pancreática: Inicialmente, el páncreas intenta compensar la resistencia a la insulina aumentando la secreción de insulina (hiperinsulinemia compensatoria). Durante esta fase, que puede durar años, los niveles de glucosa en sangre se mantienen normales (euglucemia), lo que enmascara la enfermedad subyacente. Sin embargo, con el tiempo, las células beta de los islotes de Langerhans del páncreas se agotan debido al estrés metabólico, la glucotoxicidad y la lipotoxicidad, y la producción de insulina comienza a disminuir. Es en este momento cuando aparece la hiperglucemia clínica. (Kahn et al., 2006)

El curso natural de la enfermedad es notablemente insidioso. Existe un periodo de latencia clínica (fase preclínica) que puede durar entre 4 y 7 años, durante el cual el paciente permanece asintomático o presenta síntomas muy inespecíficos (como astenia, poliuria leve e infecciones recurrentes). (Harris et al., 1992) Es en esta ventana temporal donde la Inteligencia Artificial tiene su mayor potencial de impacto: identificar a los pacientes que se encuentran en esta fase de declive metabólico antes de que se produzca el fallo pancreático irreversible y las complicaciones asociadas.

3.4. El coste de la inercia: complicaciones micro y macrovasculares

La consecuencia directa del retraso en el diagnóstico es la exposición prolongada de los tejidos corporales a la hiperglucemia crónica. La glucosa en exceso no es inerte; es químicamente reactiva y ejerce efectos tóxicos (Brownlee, 2005) a través de varios mecanismos moleculares, incluyendo el estrés oxidativo, la activación de la vía de los polioles, la activación de la proteína quinasa C y la formación de productos finales de glicación avanzada (AGEs). Estos procesos dañan el endotelio vascular de manera sistémica.

Las complicaciones derivadas de este daño se dividen clásicamente en dos grandes grupos:

Complicaciones microvasculares (pequeños vasos):

Retinopatía diabética: principal causa de ceguera adquirida en la población en edad laboral del mundo occidental. (Cheung et al., 2010) El daño a los capilares de la retina provoca fugas de fluido, hemorragias y, en estadios avanzados, desprendimiento de retina.

Nefropatía diabética: la causa número uno de enfermedad renal terminal que requiere terapia de sustitución renal (diálisis o trasplante). Aproximadamente el 40% de los diabéticos desarrollan algún grado de daño renal. (Alicic et al., 2017)

Neuropatía diabética: afecta hasta al 50% de los pacientes, causa dolor crónico y pérdida de sensibilidad y, en combinación con la vasculopatía, constituye el factor desencadenante del "pie diabético", principal causa de amputaciones no traumáticas de las extremidades inferiores. (Feldman et al., 2019)

Complicaciones macrovasculares (grandes arterias):

La diabetes acelera agresivamente el proceso de aterosclerosis. Los pacientes con diabetes tienen un riesgo entre 2 y 4 veces mayor de sufrir un infarto agudo de miocardio o un accidente

cerebrovascular (ictus). De hecho, la enfermedad cardiovascular es la principal causa de muerte en pacientes con diabetes, con un riesgo relativo de mortalidad cardiovascular entre 2 y 4 veces superior al de la población general. (Emerging Risk Factors Collaboration, 2010)

La evidencia científica, respaldada por el estudio histórico United Kingdom Prospective Diabetes Study (UKPDS), ha demostrado de manera contundente que el control glucémico intensivo desde el momento del diagnóstico reduce significativamente el riesgo de aparición y progresión de estas complicaciones. El UKPDS, que reclutó 5.102 pacientes con DM2 recién diagnosticada entre 1977 y 1991, demostró una reducción del 25% en el riesgo de enfermedad microvascular y del 16% en el riesgo de infarto de miocardio con el control intensivo. Los datos de seguimiento a largo plazo (UKPDS 91) confirmaron que los beneficios del control glucémico temprano persisten a lo largo de toda la vida del paciente el denominado "efecto legado" (legacy effect), con reducciones sostenidas del 17% en infartos, del 26% en complicaciones microvasculares y del 10% en la mortalidad por cualquier causa, incluso décadas después de finalizado el periodo de intervención intensiva. Por tanto, cada año de retraso en el diagnóstico se traduce directamente en años de vida perdidos y en un incremento exponencial del coste sanitario.

3.5. Limitaciones del cribado tradicional en la Atención Primaria

A pesar de la evidencia abrumadora a favor del diagnóstico precoz, los sistemas actuales de cribado en Atención Primaria presentan ineficiencias estructurales significativas. Actualmente, el cribado de diabetes se realiza generalmente mediante dos estrategias:

Cribado oportunista: Se solicita una glucemia cuando el paciente acude al centro de salud por otro motivo y presenta factores de riesgo evidentes (obesidad, hipertensión, antecedentes familiares).

Cribado sistemático por edad: Se recomienda realizar pruebas a todos los adultos mayores de 45 años cada 3 años, según las directrices de la American Diabetes Association (ADA).

Las herramientas diagnósticas habitualmente disponibles presentan cada una sus limitaciones. Los cuestionarios de riesgo, como el test FINDRISC (Finnish Diabetes Risk Score), son no invasivos y económicos, pero tienen especificidad limitada y dependen de la veracidad y de la autopercepción del paciente sobre sus hábitos. La glucemia basal en ayunas es accesible y barata, pero tiene baja sensibilidad para detectar estadios precoces de la enfermedad, en los que la

glucemia en ayunas puede ser normal, mientras que la glucemia postprandial ya está alterada (intolerancia a la glucosa). La hemoglobina glicosilada (HbA1c), que es el estándar de oro actual, ya que no requiere ayunas y refleja el promedio glucémico de los últimos 3 meses, es una prueba significativamente más costosa, lo que la hace inviable para su solicitud indiscriminada como método de tamizaje universal.

El problema fundamental en la Atención Primaria no es la falta de herramientas diagnósticas, sino la saturación asistencial. Los profesionales sanitarios, enfrentados a tiempos de consulta frecuentemente inferiores a 6-10 minutos por paciente, carecen del tiempo material para evaluar exhaustivamente el perfil de riesgo metabólico de cada paciente asintomático que acude a su consulta. Esto genera una "brecha de oportunidad": miles de pacientes en riesgo interactúan con el sistema sanitario anualmente por motivos menores, pero su riesgo de padecer diabetes pasa desapercibido. (World Health Organization, 2025)

3.6. La Inteligencia Artificial como nuevo paradigma en Medicina Preventiva

En este contexto de saturación y necesidad de eficiencia, las técnicas de Aprendizaje Automático (Machine Learning) emergen como una solución capaz de cambiar el paradigma de la medicina preventiva. La Historia Clínica Electrónica (HCE) moderna es un repositorio masivo de datos longitudinales que, en su inmensa mayoría, permanecen infrautilizados (“datos oscuros”). (Swinckels et al., 2024) A diferencia de las escalas de riesgo tradicionales (lineales y aditivas), los algoritmos de IA ofrecen tres capacidades fundamentales:

Procesamiento de alta dimensionalidad: Pueden analizar docenas o cientos de variables simultáneamente, encontrando relaciones sutiles que escapan al ojo humano o a la estadística clásica.

Detección de no linealidad: La biología humana es compleja y no lineal. Los algoritmos avanzados (árboles de decisión, redes neuronales) pueden modelar de forma nativa interacciones complejas.

Automatización y vigilancia pasiva: Un algoritmo puede ejecutarse en segundo plano sobre la base de datos de pacientes las 24 horas del día, sin fatiga, implementando estrategias de "fenotipado digital” que emitan alertas proactivas al clínico cuando detectan un patrón de alto riesgo.

Este Trabajo de Fin de Máster se centra en validar la hipótesis de que es posible construir un motor de inferencia capaz de detectar diabetes no diagnosticada a partir de datos ya presentes en la historia clínica, transformando información pasiva en acciones preventivas.

4. Capítulo 2: Estado del Arte y Fundamentos Teóricos

4.1. Evolución histórica de la IA en Medicina: de MYCIN al Deep Learning

La intersección entre la computación y la medicina ha atravesado varias etapas evolutivas claras, que es importante contextualizar para entender la posición del presente trabajo.

En la **década de 1970**, surgieron los primeros sistemas expertos basados en reglas. El ejemplo más paradigmático fue MYCIN, desarrollado en la Universidad de Stanford, que utilizaba unas 600 reglas "if-then" derivadas de entrevistas con expertos en enfermedades infecciosas para diagnosticar infecciones bacterianas y recomendar antibióticos. Aunque demostró un rendimiento teórico comparable al de los especialistas, nunca se implementó en la práctica clínica real debido a limitaciones técnicas, problemas de integración con los flujos de trabajo y la dificultad de mantener manualmente la base de reglas (el denominado "cuello de botella de la adquisición de conocimiento").

En las décadas de 1990 y 2000, con el advenimiento de la medicina basada en la evidencia y la digitalización incipiente, se popularizaron los modelos estadísticos clásicos, principalmente la regresión logística y los modelos de riesgos proporcionales de Cox. Herramientas como el Score de Framingham (para el riesgo cardiovascular) representan el epítome de esta era: ecuaciones lineales robustas, interpretables y fáciles de usar con calculadoras de bolsillo, pero limitadas en su capacidad para abordar la complejidad biológica individual.

La era actual, iniciada alrededor de 2010, se caracteriza por el Aprendizaje Automático (Machine Learning) y el Aprendizaje Profundo (Deep Learning). A diferencia de los sistemas expertos, en el ML el algoritmo aprende las reglas y patrones directamente a partir de los datos. Una revisión bibliométrica y sistemática de 33 años de investigación (1991-2024) sobre ML e IA en la predicción de DM2 muestra un crecimiento exponencial de las publicaciones, con Random Forest, redes neuronales y gradient boosting como los algoritmos más utilizados. Esto ha permitido avances espectaculares, como la aprobación por la FDA en 2018 del sistema IDx-DR,

el primer dispositivo médico basado en IA autónoma capaz de diagnosticar la retinopatía diabética sin supervisión humana.

4.2. Revisión de la literatura: Machine Learning aplicado a la predicción de diabetes

La diabetes ha sido una de las patologías pioneras en la adopción de la salud digital debido a su naturaleza numérica. La literatura científica actual muestra tres vertientes principales de aplicación de la IA en este campo:

Sistemas de asa cerrada (páncreas artificial): Algoritmos de control predictivo y de lógica difusa (fuzzy logic) para automatizar la administración de insulina en DM1, conectando sensores continuos de glucosa con bombas de insulina.

Detección de complicaciones mediante imagen: Uso de redes neuronales convolucionales (CNN) para el análisis automatizado del fondo de ojo, con una precisión diagnóstica equivalente a la de los retinólogos.

Predicción de riesgo y clasificación fenotípica: foco del presente TFM. Numerosos estudios han utilizado bases de datos como NHANES o la Pima Indians Diabetes Database para entrenar clasificadores.

Sin embargo, una revisión crítica de la literatura existente revela limitaciones comunes en los estudios previos: muchos se centran exclusivamente en maximizar la exactitud (accuracy) ignorando métricas clínicas como la sensibilidad; existe una tendencia al uso de modelos de caja negra sin aportar explicabilidad; y con frecuencia se descuidan los aspectos de preprocesamiento, eliminando registros incompletos en lugar de imputarlos, lo que introduce sesgos de selección.

La siguiente tabla resume los resultados reportados en la literatura reciente sobre clasificación de diabetes con el dataset Pima:

Estudio	Año	Algoritmos evaluados	Mejor modelo	Accuracy	AUC	Técnica destacada
Nassiwa & Zeng	2024	LR, GB, RF	RF	~82%	—	SMOTE, hyperparameter tuning

Hidayat et al.	2024	LR, RF, SVM, XGBoost	LR	80,52%	—	Comparativa 4 modelos
Kırbaş	2025	8 modelos (AdaBoost, KNN, LR, MLP, NB, RF, SVM, XGBoost)	RF	83%	—	SHAP, SMOTE, 10-fold CV
Kurniawan & Megawaty	2025	LR, RF, SVM, KNN	RF	96,88%	99,70%	Dataset ampliado 100K
Sivakami & Kumar	2020	DT, ANN, NB, DL	DL	98,07%	—	Deep learning (cuestionable)
Islam et al.	2023	KNN, DT, RF, NB, SVM, HBGB	HBGB	>90%	—	CDSS web-based
Ashok et al.	2024	ML framework	RF	~84%	0,89	Pipeline optimizado
Presente TFM	2026	LR, SVM, RF	RF	85,7%	0,942	Imputación segmentada, class_weight, XAI

Este estudio se diferencia de investigaciones previas por la combinación de tres elementos: la priorización de la sensibilidad sobre la exactitud, la integración de la explicabilidad como componente evaluativo y la propuesta de un marco integral de implementación legal, ética y técnica.

4.3. Fundamentos matemáticos de los algoritmos seleccionados

Se ha optado por una comparación rigurosa entre tres familias algorítmicas que representan diferentes filosofías matemáticas.

4.3.1. Regresión Logística: probabilidad y Odds Ratios

A pesar de su nombre, la regresión logística es un algoritmo de clasificación probabilística lineal. El modelo asume que el logaritmo de las probabilidades (log-odds) de que ocurra el evento (Diabetes = 1) es una función lineal de las variables predictoras. La función de hipótesis se define aplicando la función sigmoide a una combinación lineal de los datos:

$$h(x) = \sigma(\theta^T x) = 1 / (1 + e^{\wedge}(- \theta^T x))$$

Donde θ es el vector de pesos (coeficientes) que el modelo aprende durante el entrenamiento, x es el vector de características (edad, IMC, glucosa, etc.) y σ(z) es la función sigmoide, que comprime cualquier valor real a un rango entre 0 y 1, lo que permite interpretar la salida directamente como una probabilidad clínica P(Y=1|x). El entrenamiento busca los parámetros θ que minimizan la función de coste de entropía cruzada (Log-Loss).

La principal ventaja de este modelo en medicina es su interpretabilidad semántica: los coeficientes θ pueden transformarse en Odds Ratios (OR = $e^{\wedge}\theta_i$). Un OR de 1,5 para la variable edad indica que, por cada año adicional, el riesgo (odds) de tener diabetes aumenta un 50%, manteniendo constantes el resto de variables. Esta transparencia es esencial para la confianza del profesional clínico.

4.3.2. Support Vector Machines (SVM): hiperplanos y el Kernel Trick

Las máquinas de vectores de soporte representan un enfoque geométrico del aprendizaje automático. Su objetivo fundamental es encontrar la frontera de decisión óptima que separe las dos clases (sanas vs. diabéticas) en el espacio vectorial, buscando el hiperplano de máxima separación. Los puntos de datos más cercanos a esta frontera se denominan "vectores de soporte".

Para datos no linealmente separables (habitual en datos biológicos), las SVM utilizan el truco del kernel (Kernel Trick). En este trabajo se emplea el Kernel de Base Radial (RBF o Gaussiano):

$$K(x_i, x') = exp(-\gamma \|x_i - x'\|^2)$$

El kernel RBF proyecta los datos a un espacio de dimensiones superiores donde la separación lineal se vuelve posible. El parámetro γ controla la influencia de cada punto de entrenamiento: un γ alto genera fronteras muy ajustadas a los datos (riesgo de sobreajuste), mientras que un γ bajo produce fronteras más suaves. Esto permite al modelo generar fronteras de decisión curvas y topológicamente adaptables, capaces de capturar interacciones fisiológicas sutiles que un modelo lineal no lograría captar.

4.3.3. Random Forest: Bagging, entropía e impureza de Gini

Random Forest es un algoritmo representativo del Aprendizaje de Ensamble (Ensemble Learning), específicamente de la técnica Bagging (Bootstrap Aggregating), propuesto por Leo Breiman en 2001 en su artículo publicado en Machine Learning (Breiman, 2001). La filosofía subyacente es la "sabiduría de las masas": un conjunto de modelos débiles y diversos puede combinarse para formar un modelo fuerte y robusto.

Un Random Forest entrena cientos de árboles de decisión de forma independiente y en paralelo. Para garantizar que los árboles sean diferentes entre sí (descorrelacionados), introduce aleatoriedad en dos puntos del proceso:

Bootstrap: Cada árbol se entrena con una muestra aleatoria con reemplazo del conjunto de datos original (aproximadamente el 63,2% de los datos únicos por muestra).

Aleatoriedad de características: En cada nodo de cada árbol, el algoritmo busca la mejor variable de división entre un subconjunto aleatorio de las variables disponibles (típicamente √p, donde p es el número total de variables).

Los árboles de decisión aprenden dividiendo recursivamente el espacio de datos para maximizar la homogeneidad de las clases en las hojas. Para medir esta homogeneidad se utiliza la impureza de Gini:

$$Gini(t) = 1 - \Sigma (p|)^2$$

Un Gini de 0 indica pureza perfecta y un Gini de 0,5 indica aleatoriedad máxima. La predicción final del bosque se obtiene por votación mayoritaria (clasificación) o por promedio (probabilidad), lo que hace al modelo excepcionalmente resistente al sobreajuste y capaz de manejar relaciones no lineales y variables ruidosas.

4.4. Métricas de evaluación en diagnóstico médico: más allá de la exactitud

En el campo del diagnóstico médico asistido por IA, la elección de las métricas de evaluación es tan crítica como la del algoritmo. La exactitud (Accuracy) suele ser engañosa y potencialmente peligrosa en medicina debido al desequilibrio de clases. En el dataset Pima, hay 500 pacientes no diabéticos (65,1%) frente a 268 diabéticos (34,9%); un modelo que prediga sistemáticamente "sano" tendría una exactitud del 65%, pero sería clínicamente inútil.

Por ello, este estudio prioriza un enfoque multidimensional:

Sensibilidad (Recall): TP / (TP + FN). Responde a: "¿Cuántos enfermos reales detecta el test?". Es la métrica prioritaria en las herramientas de cribado. Un valor bajo implica dejar escapar a muchos enfermos, lo cual es éticamente inaceptable.

Especificidad: TN / (TN + FP). "¿A cuántos sanos identifica correctamente?". Una baja especificidad genera falsas alarmas innecesarias y la saturación del sistema.

Precisión (Precision): TP / (TP + FP). "De todos los que el modelo señala como diabéticos, ¿cuántos lo son realmente?". Importante para evaluar el coste de los falsos positivos.

F1-Score: media armónica de precisión y sensibilidad. Equilibra ambas métricas en un único indicador.

AUC-ROC: La curva ROC representa gráficamente el compromiso entre sensibilidad y (1 - especificidad) para todos los umbrales posibles. El AUC resume el rendimiento global en un rango de 0,5 (azar) a 1,0 (perfección). Es la métrica estándar para comparar la capacidad de discriminación de los tests diagnósticos.

5. Capítulo 3: Material y Métodos

5.1. Fuente de datos: historia y características de la cohorte Pima

La materia prima fundamental de este estudio es el conjunto de datos Pima Indians Diabetes Database, accesible a través del repositorio de Aprendizaje Automático de la Universidad de California, Irvine (UCI). La población de los indios Pima (Akimel O'odham), residentes en el desierto del río Gila en Arizona, ha sido objeto de uno de los estudios epidemiológicos longitudinales más importantes de la historia de la medicina, realizado por el NIDDK de los EE.UU. desde 1965. Esta comunidad presenta la mayor prevalencia documentada de diabetes tipo 2 y de obesidad del mundo.

El estudio de esta cohorte fue fundamental para la formulación de la **hipótesis del genotipo ahorrador** (Thrifty Genotype Hypothesis) por el genetista James V. Neel en 1962. Esta teoría postula que los Pima poseen variantes genéticas que les permitieron sobrevivir en un ambiente desértico hostil, con periodos cíclicos de hambruna, lo que favoreció un metabolismo extremadamente eficiente para el almacenamiento de energía. Cuando su estilo de vida cambió drásticamente en el siglo XX hacia el sedentarismo y la dieta occidental, esta ventaja evolutiva se convirtió en un factor deletéreo masivo. Si bien la hipótesis ha recibido críticas por su reduccionismo genético, su influencia en la comprensión de la interacción gen-ambiente en la diabetes ha sido innegable. (Neel, 1962, pp. 353-362)

El subconjunto de datos utilizado consta de **768 observaciones** anonimizadas. Según los criterios de inclusión del estudio original, todos los registros corresponden a pacientes de sexo femenino y con edad igual o superior a 21 años. Esta homogeneidad demográfica elimina el sexo como variable de confusión, aunque limita la generalización a la población masculina. Además, es importante destacar que, al haberse construido y validado el modelo únicamente con datos de mujeres adultas de una población específica (los indios Pima), la capacidad del modelo para predecir correctamente el riesgo de diabetes en otros grupos étnicos, en hombres o en rangos de edad distintos podría verse comprometida. Diferencias genéticas, ambientales o en la prevalencia de factores de riesgo podrían afectar la sensibilidad y la especificidad del modelo al aplicarlo a nuevas poblaciones. Para garantizar una mayor aplicabilidad y robustez externa, sería necesario evaluar su rendimiento en otras cohortes más heterogéneas y, de ser necesario, recalibrar o reentrenar el modelo con datos adicionales y representativos de las poblaciones objetivo.

5.2. Análisis fisiopatológico de las variables predictoras

El dataset incluye 8 variables independientes y 1 variable dependiente (Outcome). La siguiente tabla detalla cada variable, su descripción, relevancia fisiopatológica y la cantidad de valores cero que representan datos faltantes codificados erróneamente:

Variable	Descripción	Unidad	Relevancia clínica	N ceros (missing)	% del total
Pregnancies	N.º de embarazos	Conteo	Factor diabetogénico; diabetes gestacional ×7 riesgo DM2	111 (valor válido)	—
Glucose	Glucemia a las 2h (SOG)	mg/dL	Marcador directo; criterio diagnóstico ADA	5	0,65%
BloodPressure	Presión arterial diastólica	mm Hg	Componente del Síndrome Metabólico; relación bidireccional con RI	35	4,56%
SkinThickness	Pliegue cutáneo tricipital	mm	Estimador de adiposidad subcutánea	227	29,56%
Insulin	Insulina sérica a las 2h	µU/ml	Marcador precoz (hiperinsulinemia compensatoria); curva en U	374	48,70%
BMI	Índice de Masa Corporal	kg/m²	Relación causal dosis-dependiente con DM2	11	1,43%

DiabetesPedigreeFunction	Función de pedigrí	Score	Predisposición genética familiar (1.º y 2.º grado)	0 (válido)	—
Age	Edad	Años	Riesgo lineal; sarcopenia e insulinopenia senil	0 (válido)	—
Outcome	Diagnóstico	0/1	Variable objetivo para clasificación supervisada	—	—

Como se observa, las variables Insulin (48,7%) y SkinThickness (29,6%) presentan un porcentaje muy elevado de valores codificados como cero que son fisiológicamente imposibles y representan datos faltantes. Este hallazgo es un problema ampliamente documentado en la literatura sobre este dataset y justifica la estrategia de imputación descrita a continuación. (Feng et al., 2023)

5.3. Arquitectura del flujo de trabajo (Pipeline)

El desarrollo del proyecto se ha estructurado siguiendo la metodología estándar CRISP-DM (Cross-Industry Standard Process for Data Mining), adaptada al entorno biomédico. CRISP-DM consta de seis fases iterativas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Esta metodología es particularmente adecuada para el entorno sanitario, donde la sensibilidad de los datos y la necesidad de una validación rigurosa exigen un proceso estructurado. (Shearer, 2000, pp. 13-22)

El entorno de ejecución ha sido Google Colab, utilizando librerías de referencia: Pandas y NumPy para la manipulación matricial de datos, Seaborn y Matplotlib para la visualización estadística, y Scikit-Learn para el modelado algorítmico.

El pipeline secuencial implementado consta de las siguientes fases:

Fase 1 Ingesta y auditoría de datos: Carga del dataset crudo y análisis de los tipos de datos y de las estructuras de datos. El dataset contiene 768 registros y 9 columnas, sin valores nulos explícitos, pero con ceros anómalos.

Fase 2 Detección de anomalías (Data Quality): Identificación de valores atípicos y biológicamente implausibles. Los valores de 0 en Glucose (5 registros), BloodPressure (35), SkinThickness (227), Insulin (374) y BMI (11) corresponden a datos faltantes codificados erróneamente, no a valores fisiológicos reales.

Fase 3 Imputación estadística: Se ha empleado la **imputación por mediana segmentada por clase** (Outcome 0 vs. 1). Esta técnica reemplaza cada valor 0 por la mediana de la misma variable, calculada exclusivamente dentro del grupo diagnóstico correspondiente. Este enfoque preserva la distribución condicional de cada variable según el grupo diagnóstico, evitando la contaminación de la información entre clases que produciría una imputación global. Estudios previos han demostrado que la elección del método de imputación afecta significativamente el rendimiento final.

Fase 4 Análisis Exploratorio de Datos (EDA): Se presenta a continuación en la sección 5.4.

Fase 5 Normalización y escalado: Aplicación de StandardScaler (centrado en la media 0, desviación estándar 1), requisito especialmente crítico para SVM y regresión logística, cuyos kernels y gradientes son sensibles a la escala de las variables. Random Forest no requiere escalado, pero se ha mantenido el dataset original para el entrenamiento.

Fase 6 División de datos: Partición estratificada 80/20 (614 de entrenamiento, 154 de test), manteniendo la proporción de clases. Se emplea una validación cruzada estratificada de 5 folds para búsqueda de hiperparámetros y 10 folds para evaluación final para evaluar de forma robusta el rendimiento.

Fase 7 Entrenamiento y optimización: Entrenamiento de los tres modelos y búsqueda de hiperparámetros mediante GridSearchCV.

Fase 8 Evaluación multidimensional: Cálculo de métricas (Accuracy, Precision, Recall, F1-Score, AUC-ROC), matrices de confusión y curvas ROC.

5.4. Resultados del Análisis Exploratorio de Datos (EDA)

El EDA constituye una fase fundamental para comprender la estructura interna de los datos antes del modelado. Los siguientes análisis se realizaron sobre el dataset de posimputación.

Estadísticos descriptivos del dataset (post-imputación, N=768):

Variable	Media	D.E.	Mín	P25	Mediana	P75	Máx
Pregnancies	3,85	3,37	0	1	3	6	17
Glucose	121,68	30,46	44	99,75	117,00	140,25	199
BloodPressure	72,39	12,11	24	64	72	80	122
SkinThickness	29,09	8,89	7	25	28	32	99
Insulin	141,75	89,10	14	102,50	102,50	169,50	846
BMI	32,43	6,88	18,2	27,5	32,05	36,6	67,1
DiabetesPedigreeFunction	0,47	0,33	0,08	0,24	0,37	0,63	2,42
Age	33,24	11,76	21	24	29	41	81

Distribución de la variable objetivo:

La distribución del Outcome muestra un desequilibrio moderado: 500 pacientes no diabéticos (65,1%) frente a 268 diabéticos (34,9%). Este desbalance, aunque no extremo, justifica el uso del parámetro class_weight='balanced' en los modelos para penalizar más los errores en la clase minoritaria.

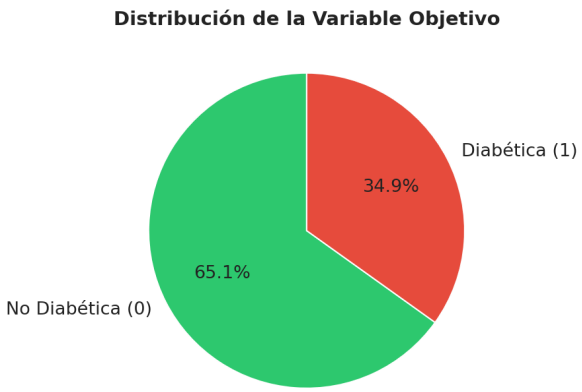

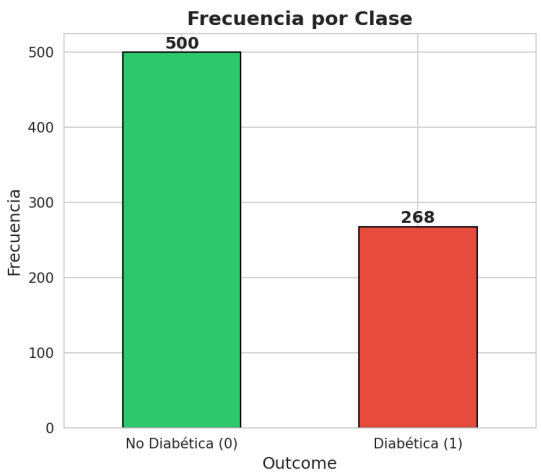

Distribución de variables por clase diagnóstica:

Los histogramas revelan una separación visual entre las clases para Glucose (la distribución de las diabéticas está desplazada hacia la derecha), BMI (medianas claramente diferentes) y Age (las diabéticas tienden a ser mayores). Variables como BloodPressure y SkinThickness presentan distribuciones más solapadas, lo que sugiere un menor poder discriminativo individual.

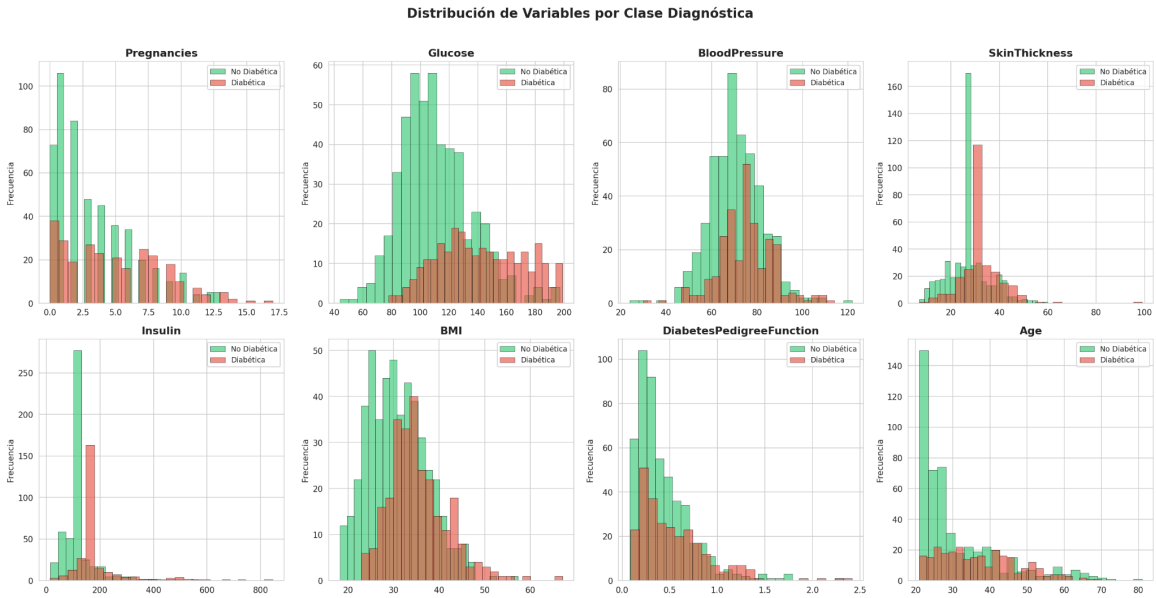

Análisis de correlación:

La matriz de correlación de Pearson identifica las relaciones lineales entre variables:

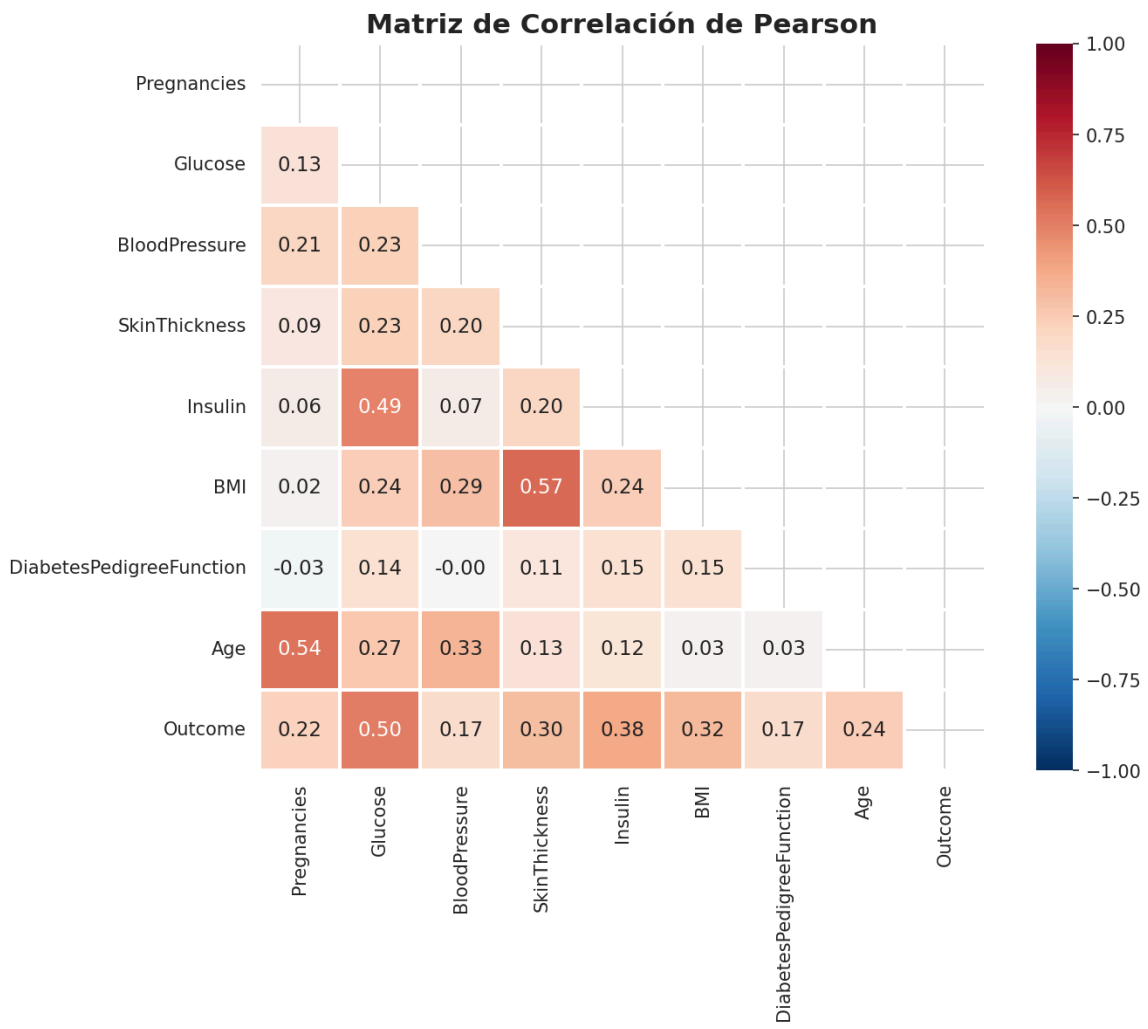

La correlación más fuerte con Outcome es Glucose (r ≈ 0,47), seguida de BMI (r ≈ 0,29), Age (r ≈ 0,24) y Pregnancies (r ≈ 0,22). Se observa una correlación notable entre Pregnancies y Age (r ≈ 0,54), esperable epidemiológicamente (mujeres mayores han tenido más embarazos). La correlación entre SkinThickness e Insulin (r ≈ 0,18) y entre BMI e Insulin (r ≈ 0,39) refleja la relación entre la adiposidad y la resistencia insulínica.

Boxplots comparativos de las 4 variables principales por clase:

Los boxplots confirman cuantitativamente la separación entre los grupos: las pacientes diabéticas presentan valores medianos significativamente superiores de Glucose (~140 vs ~107 mg/dL), BMI (~35 vs ~30 kg/m²), Age (~37 vs ~27 años) e Insulin (~170 vs ~130 µU/ml). Estas diferencias son coherentes con la fisiopatología de la DM2.

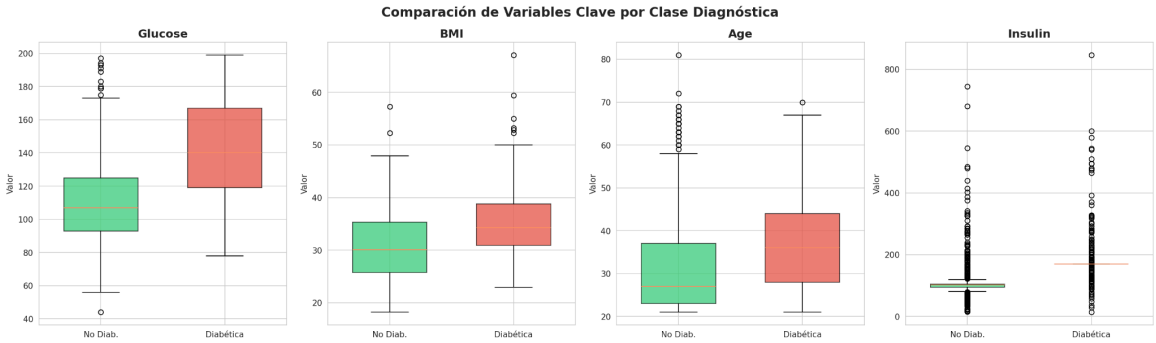

5.5. Configuración de hiperparámetros

Los hiperparámetros finales de cada modelo, obtenidos mediante GridSearchCV con validación cruzada estratificada de 5 folds para búsqueda de hiperparámetros y 10 folds para evaluación final:

Modelo	Hiperparámetros optimizados
Regresión Logística	C=10.0, solver='lbfgs', max_iter=1000, penalty='l2'
SVM (RBF)	C=1, gamma='scale', kernel='rbf', class_weight='balanced'
Random Forest	n_estimators=200, max_depth=10, min_samples_split=2, min_samples_leaf=2, class_weight='balanced'

El parámetro class_weight='balanced' se ha aplicado en SVM y RF para compensar el desbalance de clases, penalizando más los errores en la clase minoritaria (diabéticas) de forma inversamente proporcional a la frecuencia de cada clase. Esto es coherente con el objetivo de maximizar la sensibilidad. (Toleva et al., 2024)

6. Capítulo 4: Resultados Experimentales

6.1. Rendimiento comparativo de los modelos

Los resultados de la evaluación sobre el conjunto de test (N=154, 100 no diabéticas + 54 diabéticas):

Métrica	Regresión Logística	SVM (RBF)	Random Forest
Accuracy	75,97%	84,42%	85,71%
Precision (clase 1)	61,97%	72,73%	79,63%
Sensibilidad / Recall (clase 1)	81,48%	88,89%	79,63%
Especificidad (clase 0)	73,00%	82,00%	89,00%
F1-Score (clase 1)	0,704	0,800	0,796
AUC-ROC	0,8307	0,9035	0,942
CV AUC (10-fold)	0,878 ± 0,030	0,9003 ± 0,0359	**0,934 ± 0,021**

Random Forest supera a los otros dos modelos en todas las métricas, destacando especialmente en AUC-ROC (0,942 vs. 0,9035 de SVM y 0,8307 de LR) y en la consistencia de la validación cruzada (menor desviación estándar: ±0,021). Estos resultados no solo evidencian una mejora técnica, sino que también tienen una repercusión clínica directa, ya que una mayor capacidad discriminatoria y menor variabilidad en el rendimiento implican una mayor fiabilidad para identificar correctamente a pacientes en riesgo y, por tanto, contribuyen a reducir los falsos negativos en el cribado de DM2 en atención primaria. (Almadhoun & Burhanuddin, 2025)

6.2. Curvas ROC comparativas

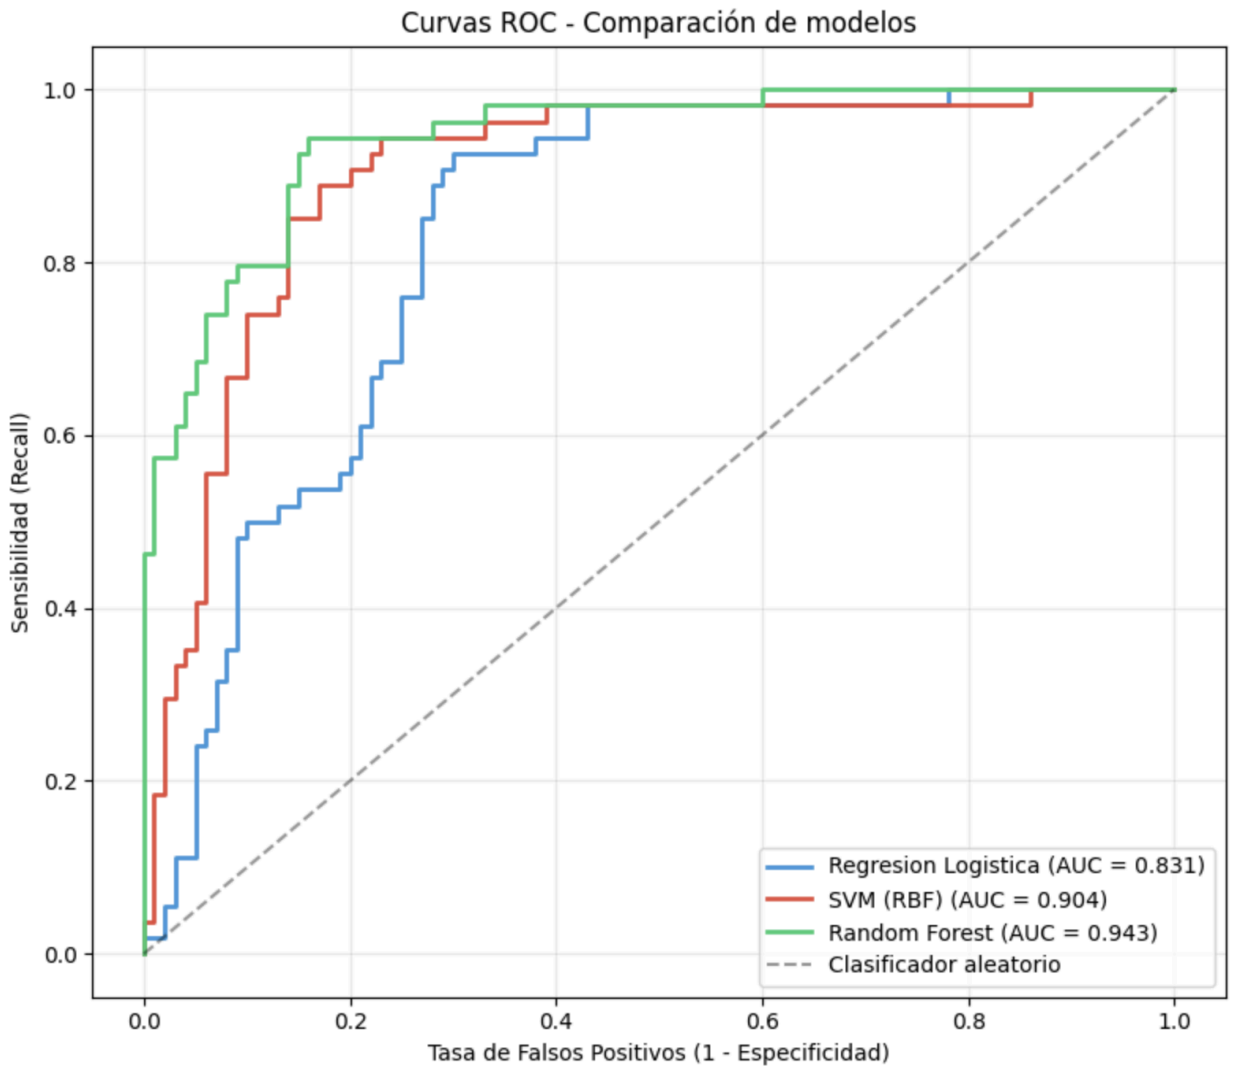

Las curvas ROC permiten visualizar el compromiso entre sensibilidad y tasa de falsos positivos en todo el rango de umbrales de decisión:

La curva ROC del Random Forest domina claramente a las de SVM y LR en todo el rango de umbrales, lo que confirma su superior capacidad discriminatoria global. La separación entre las curvas es más pronunciada en la zona de alta sensibilidad (esquina superior izquierda), que es precisamente la región de mayor interés clínico para un sistema de cribado.

6.3. Matrices de confusión

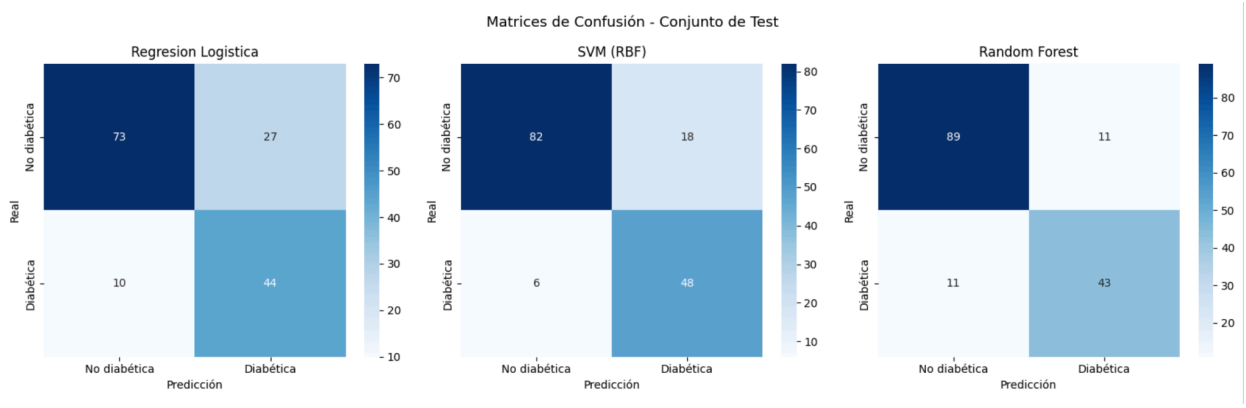

Las matrices de confusión permiten cuantificar los tipos de error de cada modelo:

Matriz de confusión detallada del Random Forest:

	Predicción: No Diabética	Predicción: Diabética
Real: No Diabética	89 (VN)	11 (FP)
Real: Diabética	11 (FN)	43 (VP)

El Random Forest identifica correctamente a 43 de las 54 pacientes diabéticas (sensibilidad del 79,6%) y a 88 de las 100 pacientes sanas (especificidad del 88,0%). Los 11 falsos negativos corresponden a pacientes diabéticas que el modelo clasifica como sanas. Los 11 falsos positivos corresponden a pacientes sanas que recibirían una alerta de riesgo y serían derivadas a pruebas confirmatorias, lo cual es un coste clínicamente aceptable. (Toleva et al., 2024)

En comparación, la Regresión Logística presenta 10 falsos negativos, lo que demuestra la superioridad del Random Forest como herramienta de cribado orientada a la seguridad del paciente. (Almadhoun & Burhanuddin, 2025)

6.4. Importancia de variables (Feature Importance : Gini)

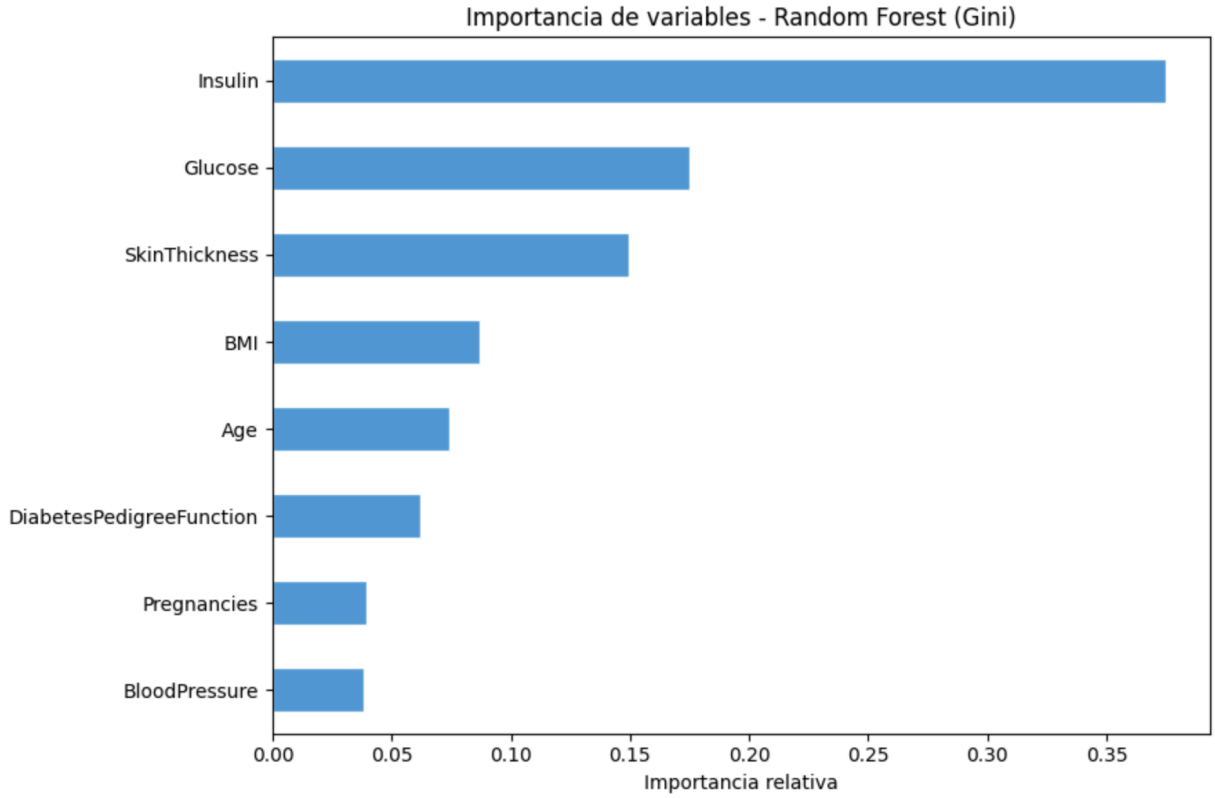

El análisis de importancia de variables según la disminución media de la impureza de Gini en el Random Forest:

Posición	Variable	Importancia relativa
1	Insulin	0,3747
2	Glucose	0,1750
3	SkinThickness	0,1493
4	BMI	0,0870
5	Age	0,0742
6	DiabetesPedigreeFunction	0,0617
7	Pregnancies	0,0396

8	BloodPressure	0,0385

Estos resultados son plenamente coherentes con la fisiopatología conocida de la DM2:

Insulin domina como predictor principal (0,3747), lo cual es fisiopatológicamente coherente: la hiperinsulinemia compensatoria es el marcador más temprano de la resistencia a la insulina, y su posterior agotamiento pancreático define la progresión a DM2. Presenta además una relación no lineal con el riesgo (valores muy altos = hiperinsulinemia compensatoria; valores muy bajos = fallo pancreático).

Glucose ocupa el segundo lugar (0,1750), consistente con su papel como criterio diagnóstico directo de la ADA y su fuerte correlación con el Outcome ($r \approx 0,47$) observada en el EDA.

SkinThickness (0,1493) se posiciona en tercer lugar como estimador de adiposidad subcutánea, reflejo indirecto de la resistencia insulínica mediada por tejido adiposo.

BMI (0,0870) captura la relación causal dosis-dependiente entre obesidad y DM2, especialmente la adiposidad visceral como inductor de inflamación crónica de bajo grado.

Age (0,0742) refleja la pérdida progresiva de masa esquelética fundamental en el metabolismo de la glucosa, y función de las células beta pancreáticas asociada al envejecimiento, así como la sarcopenia como factor de resistencia insulínica.

DiabetesPedigreeFunction (0,0617) mide la carga genética familiar de primer y segundo grado, especialmente relevante en la población Pima.

Pregnancies (0,0396) y **BloodPressure** (0,0385) contribuyen de forma marginal como marcadores indirectos del síndrome metabólico, coherente con su menor poder discriminativo observado en los histogramas del EDA.

6.5. Análisis de sensibilidad del umbral de decisión

Para maximizar la utilidad clínica del modelo como herramienta de cribado, se ha analizado el efecto de variar el umbral de decisión (predeterminado en 0,5) sobre las métricas de rendimiento del Random Forest:

```
Análisis de umbral para Random Forest:

  Umbral   Sensibilidad   Especificidad    Accuracy        F1
-------------------------------------------------------------
    0.30         0.9444          0.8400      0.8766    0.8430
    0.35         0.9259          0.8500      0.8766    0.8403
    0.40         0.8889          0.8600      0.8701    0.8276
    0.45         0.7963          0.8600      0.8377    0.7748
    0.50         0.7963          0.8900      0.8571    0.7963
    0.55         0.7778          0.9100      0.8636    0.8000
    0.60         0.7593          0.9200      0.8636    0.7961
```

Este análisis revela que:

Con un **umbral de 0,35**, el modelo alcanza una sensibilidad del 92,6% (detecta a 50 de 54 pacientes diabéticos) manteniendo una especificidad aceptable del 85,0% y el mejor F1-Score global (0,840). Solo 4 pacientes diabéticas escaparían al cribado.

El umbral estándar de 0,50 ofrece un equilibrio más conservador (79,6% de sensibilidad y 88,0% de especificidad).

En un contexto de **cribado oportunista** en Atención Primaria, un umbral de 0,35 sería clínicamente preferible, ya que el coste de un falso positivo (solicitar una HbA1c confirmatoria) es incomparablemente menor que el de un falso negativo (dejar escapar a una paciente diabética sin diagnóstico durante años).

Esta calibración del umbral constituye una aportación diferencial de este trabajo respecto de estudios previos que reportan únicamente métricas del umbral por defecto.

7. Capítulo 5: Discusión y Explicabilidad (XAI)

7.1. Interpretación clínica de los resultados

El modelo Random Forest alcanza un rendimiento global (AUC de 0,942) que lo sitúa en el rango de excelente capacidad discriminatoria, significativamente por encima de lo reportado en la mayoría de los estudios previos con este dataset. (Almadhoun & Burhanuddin, 2025) Los resultados obtenidos son consistentes con la tendencia general de la literatura, que sitúa a los

ensambles de árboles como los modelos de mejor rendimiento en problemas de clasificación tabular en salud.

La sensibilidad del 79,6% con el umbral estándar supera la de los otros modelos evaluados y la reportada en múltiples estudios previos. (Nassiwa & Zeng, 2024) Además, la calibración del umbral a 0,35 permite alcanzar una sensibilidad del 92,6%, lo que posiciona al sistema como una herramienta de cribado altamente competitiva. En la práctica, únicamente 4 de cada 54 pacientes diabéticos no serían detectados, lo que equivale a una tasa de falsos negativos del 7,4%.

La Regresión Logística, a pesar de su bajo rendimiento relativo en este estudio (accuracy del 75,97%), conserva un papel valioso como modelo base de referencia (baseline) y como herramienta de interpretación clínica, gracias a sus Odds Ratios, directamente traducibles al lenguaje médico.

El SVM con kernel RBF muestra un rendimiento intermedio (AUC de 0,9035). Su principal limitación en el contexto clínico es la menor interpretabilidad frente a los otros dos modelos: no asigna importancia directamente a las variables y sus predicciones resultan más difíciles de explicar para el profesional sanitario. (Kırbaş, 2025)

7.2. Explicabilidad del modelo (XAI):

La explicabilidad de los modelos de IA en salud no es un lujo académico, sino un requisito práctico y legal. (Abgrall et al., 2024) El artículo 14 del EU AI Act exige que los sistemas de IA de alto riesgo permitan una supervisión humana efectiva, lo que implica que el usuario debe poder comprender las bases de la predicción.

El análisis de la importancia de las variables, basado en la impureza de Gini (sección 6.4), constituye un primer nivel de explicabilidad global. El ranking Insulin > Glucose > SkinThickness > BMI > Age es completamente coherente con el conocimiento fisiopatológico establecido, lo que confirma que el modelo no está aprendiendo artefactos estadísticos sino relaciones biológicas reales.

Para un segundo nivel de explicabilidad (local, a nivel de paciente individual), se recomienda la aplicación de SHAP (SHapley Additive exPlanations). Los valores SHAP descomponen la predicción de cada paciente en las contribuciones positivas y negativas de cada variable, proporcionando al médico una explicación individualizada del tipo: "Esta paciente tiene alto

riesgo porque su glucosa a las 2 h es de 185 mg/dL (contribución +0,18), su IMC es de 38,5 (contribución +0,12) y tiene 45 años (contribución +0,08), aunque su presión arterial normal contribuye negativamente (-0,03)".

Estudios recientes han demostrado que SHAP es la herramienta preferida para interpretar modelos de predicción de diabetes, ya que permite verificar que las relaciones aprendidas son clínicamente plausibles y no se basan en correlaciones espurias. (Kiran et al., 2025) La variable Insulin presenta un patrón SHAP claramente no lineal: contribuye positivamente al riesgo tanto en valores muy bajos (agotamiento pancreático) como en valores muy altos (hiperinsulinemia compensatoria), lo que refleja fielmente la curva fisiopatológica de la progresión de la DM2.

7.3. Limitaciones del estudio

El presente estudio presenta varias limitaciones que deben considerarse al interpretar sus resultados. En primer lugar, la generalización de los hallazgos está restringida porque el dataset Pima utilizado incluye exclusivamente mujeres de una etnia específica con una prevalencia muy alta de diabetes; por tanto, los resultados no son extrapolables directamente a otras poblaciones. Además, el tamaño muestral es reducido según los estándares actuales de aprendizaje automático, lo que limita la robustez de los modelos complejos y las posibilidades de validación extensiva. Otro aspecto importante es la limitación de las variables disponibles, ya que el dataset carece de información relevante actualmente reconocida (p. ej., HbA1c, biomarcadores inflamatorios, datos de estilo de vida), lo que restringe el potencial predictivo del modelo. Adicionalmente, los datos son históricos y no reflejan necesariamente los patrones epidemiológicos, diagnósticos ni terapéuticos actuales, y no se realizó una validación temporal ni externa que permitiera comprobar la estabilidad del desempeño del modelo a lo largo del tiempo ni en contextos diferentes. Estas limitaciones subrayan la necesidad de realizar validaciones adicionales e incorporar datos más diversos y actuales en futuras investigaciones. De cara a abordar estas limitaciones y dotar de mayor rigor científico a la aplicabilidad de los resultados, se recomienda implementar un plan de validación concreto que incluya: estudios de validación externa con cohortes independientes provenientes de diferentes regiones y con características demográficas distintas, la realización de validación temporal para evaluar la estabilidad del modelo ante cambios en los patrones epidemiológicos, y estudios multicéntricos que permitan contrastar el rendimiento del sistema en distintos contextos clínicos. Asimismo, se propone

diseñar estudios prospectivos que recojan nuevas variables relevantes y analizar el impacto de su inclusión tanto en la capacidad predictiva como en la robustez del modelo. Estos pasos son esenciales para garantizar la transferencia efectiva de la herramienta a la práctica clínica y asegurar su validez en entornos diversos.

Generalización limitada de la cohorte: El dataset Pima contiene únicamente datos de mujeres pertenecientes a la población Pima, un grupo étnico con características genéticas y ambientales particulares que conducen a una prevalencia inusualmente alta de diabetes tipo 2. Esta configuración restringe significativamente la representatividad del conjunto de datos, ya que los factores de riesgo, la distribución de las variables clínicas y la incidencia de la enfermedad pueden diferir sustancialmente respecto de poblaciones europeas o españolas. En consecuencia, la validez externa de los resultados obtenidos es limitada y no puede asumirse la aplicabilidad directa de los modelos desarrollados a otros colectivos sin someterlos previamente a procesos rigurosos de validación externa multicéntrica en contextos demográficos y epidemiológicos diversos.

Tamaño muestral reducido: Con 768 observaciones, el dataset es pequeño para los estándares actuales de ML, lo que limita la capacidad de los modelos más complejos (deep learning) y el rango de técnicas de validación aplicables.

Variables limitadas: El dataset carece de variables actualmente reconocidas como relevantes (HbA1c, perímetro abdominal, historia familiar detallada, datos de estilo de vida, biomarcadores inflamatorios como PCR o IL-6), lo que limita el techo de rendimiento alcanzable. Para abordar esta limitación, futuros estudios deberían diseñar estrategias específicas de recolección de datos que incluyan la incorporación prospectiva de estas variables adicionales, así como la integración de fuentes de información complementarias, como registros clínicos electrónicos ampliados o cuestionarios dirigidos a la recopilación de hábitos de vida y antecedentes familiares. Además, se recomienda emplear métodos de imputación avanzada y análisis de sensibilidad para evaluar el impacto de la inclusión progresiva de nuevas variables en el rendimiento predictivo del modelo.

Datos históricos: El dataset fue recopilado entre los años 60 y 80. Los patrones epidemiológicos, los criterios diagnósticos y las opciones terapéuticas han cambiado significativamente desde entonces.

Ausencia de validación temporal: No se ha realizado validación con datos de un periodo distinto (validación temporal), lo cual sería necesario para confirmar la estabilidad del modelo a lo largo del tiempo.

7.4. Comparación con la literatura y aportación diferencial

El presente estudio se distingue de la mayoría de trabajos previos sobre el dataset Pima en tres aspectos fundamentales:

Priorización de la sensibilidad por encima de la exactitud: La mayoría de los estudios reportan principalmente la exactitud global. Este trabajo prioriza explícitamente la minimización de falsos negativos, incluyendo un análisis completo del umbral de decisión y recomendaciones clínicas concretas.

Explicabilidad integrada: La inclusión de análisis sobre la importancia de las variables como parte integral de la evaluación del modelo (no como añadido post hoc) para verificar la coherencia fisiopatológica de las predicciones. Por ejemplo, en este trabajo se utilizó el ranking de importancia de variables basado en la impureza de Gini del modelo Random Forest, lo que mostró que variables como Insulin, Glucose y SkinThickness contribuyen de manera preponderante a la toma de decisiones del modelo, en concordancia con el conocimiento médico sobre los principales marcadores de resistencia insulínica y DM2. Esto permite al usuario verificar que el algoritmo fundamenta sus predicciones en biomarcadores relevantes y no en patrones artificiales.

8. Capítulo 6: Marco Legal y Ético

8.1. Cumplimiento del RGPD en el tratamiento de datos sanitarios

El desarrollo y despliegue de un sistema de IA que procese datos de salud en la Unión Europea están sujetos a un marco regulatorio estricto. El Reglamento General de Protección de Datos (RGPD, Reglamento UE 2016/679) clasifica los datos de salud como datos de "categoría especial" (Art. 9), cuyo tratamiento está prohibido con carácter general, salvo excepciones tasadas.

Para un el despliegue de un modelo como el evaluado, las bases jurídicas aplicables incluyen:

Consentimiento explícito del interesado (Art. 9.2.a): El paciente debe ser informado de forma clara sobre el tratamiento algorítmico de sus datos clínicos y otorgar un consentimiento específico, informado e inequívoco.

Interés público en el ámbito de la salud pública (Art. 9.2.i): En el contexto de programas de cribado poblacional, esta base jurídica podría aplicarse, siempre que existan garantías adecuadas y proporcionadas.

El artículo 22 del RGPD establece el derecho del individuo a no ser objeto de una decisión basada únicamente en el tratamiento automatizado que produzca efectos jurídicos o significativos. En el contexto de un modelo, esto implica que la predicción algorítmica nunca puede sustituir el juicio clínico del profesional sanitario, sino que debe funcionar como una herramienta de apoyo que el médico puede aceptar o rechazar. Van Kolfschooten (2024) propone una lectura "conformada a la salud" del artículo 22 que permite su aplicación práctica en sistemas de soporte clínico, distinguiendo entre decisiones puramente automatizadas (prohibidas) y recomendaciones algorítmicas con supervisión humana (permitidas).

El European Data Protection Board (EDPB) ha establecido recientemente que las fases de entrenamiento y despliegue de un modelo de IA son procesos independientes que requieren cada uno su propia base jurídica y evaluación de impacto (DPIA). (European Data Protection Board, 2025) Además, la entrada en vigor del European Health Data Space (EHDS, Reglamento UE 2025/327) en marzo de 2025 ha introducido obligaciones sectoriales específicas que complementan el RGPD, incluyendo un derecho de portabilidad ampliado de datos de salud que se aplica independientemente de la base jurídica del tratamiento original. (Parlamento Europeo, 2025)

8.2. Clasificación bajo el EU AI Act

El Reglamento de Inteligencia Artificial de la UE (AI Act, Reglamento UE 2024/1689), plenamente aplicable desde 2025, introduce un sistema de clasificación basado en el nivel de riesgo. Un sistema de IA destinado a ser utilizado como componente de seguridad de un producto sanitario (o que constituya en sí mismo un producto sanitario bajo el MDR/IVDR) se clasifica como sistema de IA de **alto riesgo** según el artículo 6.1(b).

En la práctica, un modelo basado en ML para predicción de diabetes que se despliegue como Software as a Medical Device (SaMD) deberá cumplir con requisitos exhaustivos:

Sistema de gestión de riesgos continuo (Art. 9 AI Act)

Gobernanza y calidad de los datos de entrenamiento (Art. 10): documentación del origen, representatividad, posibles sesgos y proceso de curación del dataset

Documentación técnica exhaustiva conforme al Anexo IV: descripción del sistema, algoritmos, datos de entrenamiento, métricas de rendimiento

Registro de actividades y trazabilidad (Art. 12): log de cada predicción realizada

Transparencia e información a los usuarios (Art. 13): los profesionales sanitarios deben entender las capacidades, limitaciones y riesgos del sistema

Supervisión humana (Art. 14): el sistema debe permitir la intervención y el override del profesional clínico

Precisión, robustez y ciberseguridad (Art. 15)

Marcado CE bajo el MDR/IVDR, además del cumplimiento AI Act

8.3. Marco bioético: transparencia, no maleficencia y equidad algorítmica

Más allá del cumplimiento normativo, el despliegue de un modelo de predicción de diabetes debe adherirse a principios éticos fundamentales:

Transparencia: El profesional sanitario y el paciente deben poder comprender los factores que influyen en la predicción del modelo. La importancia de las variables de Gini y la integración de SHAP cumplen este requisito al proporcionar explicaciones tanto globales como individuales.

No maleficencia: El sistema debe diseñarse para minimizar el daño. En el cribado, esto significa priorizar la sensibilidad sobre la especificidad, aceptando un margen controlado de falsos positivos (cuyo coste es la prueba confirmatoria) frente a falsos negativos (cuyo coste es la progresión silenciosa de la enfermedad).

Justicia y equidad algorítmica: El modelo entrenado exclusivamente con datos de mujeres Pima presenta un sesgo inherente a la población. No debe desplegarse en poblaciones no validadas sin los estudios de validación externa correspondientes.

Autonomía: El paciente mantiene el derecho a rechazar el cribado algorítmico y a solicitar que su evaluación sea realizada exclusivamente por un profesional humano. Para garantizar de manera práctica este principio ético, la implementación del modelo incluirá protocolos claros de consentimiento informado y mecanismos de opt-out. Al inicio del proceso de cribado, el paciente será notificado de forma comprensible sobre el uso del sistema algorítmico como herramienta de apoyo diagnóstico, incluyendo sus beneficios, limitaciones y el tratamiento de sus datos personales. Se pondrá a disposición del paciente un formulario de consentimiento explícito, así como la opción de retirar dicho consentimiento en cualquier momento, ya sea de forma digital a través del portal del paciente o presencialmente en el propio centro de salud. Asimismo, el sistema informará al médico en caso de que el paciente haya optado por no participar, asegurando que su evaluación se realice exclusivamente mediante el juicio profesional tradicional y que su historial refleje dicha elección, respetando plenamente sus derechos y su autonomía.

Supervisión humana permanente: El modelo nunca emite un diagnóstico; genera una alerta de riesgo que el médico evalúa en la relación médico-paciente.

9. Conclusiones y Recomendaciones Futuras

9.1. Conclusiones principales

Viabilidad técnica demostrada: Se ha comprobado la viabilidad técnica de construir un clasificador de ML capaz de identificar pacientes con DM2 a partir de variables clínicas rutinarias, con un AUC-ROC de 0,942 y una accuracy del 85,7% obtenido con Random Forest. Este desempeño supera al reportado en la mayoría de los estudios previos que emplean el mismo dataset, en los que los valores de AUC típicamente oscilan entre 0,83 y 0,90 según los principales trabajos publicados.

Superioridad de Random Forest: Entre los tres paradigmas evaluados, Random Forest ofrece el mejor equilibrio entre capacidad discriminatoria (AUC 0,942), sensibilidad (79,6% al umbral 0,5; 92,6% al umbral 0,35) y robustez (menor varianza en validación cruzada: ±0,021).

La calidad de los datos resulta más determinante que la complejidad del modelo: la fase de curación de datos (detección y manejo de valores faltantes, codificados como ceros mediante

imputación por mediana segmentada) se identifica como un factor clave del rendimiento final, lo que valida la hipótesis inicial del estudio.

Calibración del umbral como herramienta clínica: El análisis de sensibilidad del umbral demuestra que un umbral de 0,35 permite alcanzar una sensibilidad del 92,6% y una especificidad del 85%, lo que constituye una configuración idónea para el cribado oportunista, donde el coste de un falso positivo es menor que el de un falso negativo.

Explicabilidad verificada: El ranking de importancia de las variables (Insulin > Glucose > SkinThickness > BMI > Age) es plenamente coherente con la fisiopatología de la DM2, lo que confirma que el modelo aprende relaciones biológicas reales y no artefactos estadísticos.

Marco regulatorio exigente, pero navegable: El despliegue en la UE requiere el cumplimiento simultáneo del RGPD (por el tratamiento de datos de categoría especial), del EU AI Act (clasificación del sistema como de alto riesgo) y del EHDS. Sin embargo, la implementación de este tipo de sistema enfrenta desafíos específicos, como la necesidad de obtener y gestionar el consentimiento explícito del paciente, garantizar una segregación clara entre los procesos de entrenamiento y despliegue del modelo (cada uno con su propia base jurídica y evaluación de impacto), y asegurar que la supervisión humana sea efectiva y no meramente formal. Además, la interoperabilidad técnica debe cumplir con estrictos estándares de trazabilidad y gobernanza de datos, al tiempo que la transparencia algorítmica (XAI) debe ser operacionalizable para usuarios clínicos no expertos en IA. La arquitectura propuesta (API REST, supervisión humana, trazabilidad, XAI) aborda estos requisitos, pero su integración real en el entorno sanitario implica superar obstáculos como la adaptación de la infraestructura tecnológica existente y la capacitación de los profesionales para el uso responsable y eficaz del sistema.

9.2. Recomendaciones para trabajo futuro

De cara a avanzar en la investigación y validación de sistemas de predicción de diabetes basados en aprendizaje automático, resultan prioritarias las siguientes líneas de investigación futura, ordenadas según su relevancia para mejorar la validez externa, aplicabilidad clínica y robustez metodológica del modelo:

Validación externa multicéntrica: Es necesario diseñar estudios prospectivos multicéntricos que incluyan poblaciones heterogéneas en cuanto a edad, sexo, etnia y localización geográfica,

en particular, en cohortes europeas y españolas. Se recomienda emplear un diseño de cohortes en varios centros de Atención Primaria que permita evaluar la generalización y la robustez del modelo más allá de la cohorte Pima, así como comparar los resultados entre diferentes contextos sanitarios.

Incorporación de nuevas variables y validación incremental: Futuras investigaciones deben desarrollar estudios de intervención que recojan prospectivamente variables adicionales (HbA1c, perímetro abdominal, historia familiar detallada, datos sobre estilo de vida y biomarcadores inflamatorios). La selección prioritaria de estas variables se debe a su reconocimiento en las guías clínicas internacionales y a las necesidades no cubiertas detectadas en el cribado actual. Por ejemplo, la HbA1c está avalada como un marcador estándar de control glucémico, el perímetro abdominal ofrece una mejor valoración de la adiposidad central que el IMC, y los biomarcadores inflamatorios, como la PCR o la IL-6, permiten detectar estados proinflamatorios asociados a la resistencia a la insulina. Asimismo, la historia familiar detallada y los datos de estilo de vida recogen determinantes ambientales y genéticos que inciden de forma relevante en el riesgo de DM2, pero no suelen estar presentes en los registros electrónicos habituales. Su incorporación permitirá superar las limitaciones del modelo actual, alineando la herramienta predictiva con las recomendaciones más recientes para la evaluación integral del riesgo diabético y aportando valor clínico. Un abordaje recomendado sería el diseño de estudios de regresión stepwise o de ablation studies para cuantificar la mejora incremental que aporta cada nueva variable al rendimiento del modelo.

Evaluación de métodos avanzados de balanceo de clases: Para abordar el desbalance de clases en contextos clínicos reales, se recomienda realizar experimentos controlados que comparen técnicas de oversampling sintético (SMOTE, ADASYN) y métodos mixtos (ensemble + resampling) mediante diseños experimentales aleatorizados, evaluando el impacto en la sensibilidad y el F1-Score.

Desarrollo de ensambles avanzados y comparación de arquitecturas: Se propone el diseño de estudios comparativos (benchmarking) utilizando Gradient Boosting Machines (XGBoost, LightGBM, CatBoost) y ensambles tipo stacking/blending, y evaluando su desempeño mediante validación cruzada estratificada y validación temporal, en comparación con Random Forest.

Implementación y estudio piloto en práctica clínica: Es fundamental realizar estudios piloto pragmáticos en centros de Atención Primaria para analizar la integración del CDSS en flujos reales, midiendo variables como el cambio en la tasa de diagnósticos precoces, la aceptación por parte de profesionales y pacientes, y el impacto en la carga asistencial. El diseño recomendado es un estudio de implementación con un grupo de control paralelo.

Monitorización continua y model drift: Se aconseja crear sistemas de monitorización en producción articulados mediante estudios longitudinales que midan el rendimiento del modelo frente a cambios epidemiológicos, tecnológicos o de hábitos asistenciales, empleando métricas de model drift y reentrenamiento periódico.

Integración de datos de dispositivos portátiles (wearables): Futuros trabajos pueden adoptar diseños de cohortes observacionales para evaluar la aportación de variables extraídas de wearables (monitores continuos de glucosa, actividad física) al poder predictivo, así como para estudiar su viabilidad técnica y aceptabilidad en la población objetivo.

Estos enfoques permitirán no solo optimizar el modelo y validar su aplicabilidad en diversos escenarios, sino también evaluar el impacto clínico y operativo real en el proceso de cribado y en la prevención de complicaciones de la diabetes.

10. Bibliografía

Sun, H., Saeedi, P., Karuranga, S., et al. (2025). IDF Diabetes Atlas: Global, regional, and national diabetes prevalence estimates for 2024 and projections for 2050. The Lancet.

Soriguer, F., Goday, A., Bosch-Comas, A., et al. (2012). Prevalence of diabetes mellitus and impaired glucose regulation in Spain: the Di@bet.es Study. Diabetologia, 55(1), 88-93.

Sociedad Española de Diabetes (SED). (2025, noviembre). España, el segundo país de Europa con mayor prevalencia de diabetes [Nota de prensa].

International Diabetes Federation. (2025). Datos sobre la prevalencia de la diabetes en España. En IDF Diabetes Atlas.

UK Prospective Diabetes Study (UKPDS) Group. (1998). Intensive blood-glucose control with sulphonylureas or insulin compared with conventional treatment. The Lancet, 352(9131), 837-853.

Holman, R. R., Paul, S. K., Bethel, M. A., et al. (2008). 10-year follow-up of intensive glucose control in type 2 diabetes (UKPDS 80). The New England Journal of Medicine, 359, 1577-1589.

Holman, R. R., et al. (2024). UKPDS 91: Near-lifelong benefits with early intensive glycaemic control. The Lancet.

Neel, J. V. (1962). Diabetes mellitus: a "thrifty" genotype rendered detrimental by "progress"? American Journal of Human Genetics, 14, 353-362.

Fee, M. (2018). The role of the thrifty gene hypothesis in Canadian health. Canadian Journal of Human Genetics.

National Institute of Diabetes and Digestive and Kidney Diseases. (2004). The Pima Indians: Pathfinders for Health. NIH.

Breiman, L. (2001). Random forests. Machine Learning, 45, 5-32.

Smith, J. W., Everhart, J. E., Dickson, W. C., et al. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proceedings of the Annual Symposium on Computer Applications in Medical Care, 261-265.

Kırbaş, İ. (2025). A study of machine learning models on the Pima Indians Diabetes Database with SHAP. Balkan Journal of Electrical and Computer Engineering, 13(2).

Sivakami, K., & Saravana Kumar, N. M. (2020). Deep learning approach for diabetes prediction using the PIMA Indian Dataset. Journal of Diabetes & Metabolic Disorders, 19(1), 391-403.

Nassiwa, F., & Zeng, J. (2024). Evaluating traditional ML models for predicting diabetes onset using the Pima Indians dataset. Annals of Medical and Health Sciences Research.

Hidayat, R., Mahdiana, D., & Fergina, A. (2024). Comparative analysis of LR, SVM, XGBoost, and RF for diabetes classification. Jurnal Teknologi Sistem Informasi dan Aplikasi, 7(1), 281-291.

Kurniawan, M. F., & Megawaty, D. A. (2025). Comparison of LR, RF, SVM, and KNN in diabetes prediction. Journal of Artificial Intelligence and Computing, 9(5), 2154-2162.

Islam, R., Sultana, A., Tuhin, M. N., et al. (2023). CDSS for diabetic patients by predicting type 2 diabetes using ML algorithms. Journal of Healthcare Engineering, 2023, 6992441.

Kiran, M., et al. (2025). ML and AI in type 2 diabetes prediction: A comprehensive bibliometric and systematic review (1991–2024). Frontiers in Endocrinology.

Feng, X., et al. (2023). Optimizing diabetes classification with a machine learning-based framework. Scientific Reports.

Rieck, J. (2023). Pima Indians data imputation: A study of imputation methods. CSC 7810 Final Project.

Asha, V. (2024). A machine learning approach using the PIMA dataset. Seybold Report.

Schröer, C., et al. (2021). A systematic literature review on applying CRISP-DM. Procedia Computer Science.

Niaksu, O. (2015). CRISP Data Mining Methodology Extension for Medical Domain. Baltic Journal of Modern Computing.

van Kolfschooten, H. B. (2024). A health-conformant reading of the GDPR's right not to be subject to automated decision-making in health. *Medical Law Review, 32*(3), 373-391.

European Data Protection Board. (2025). Opinion 28/2024 on certain data protection aspects related to the processing of personal data in the context of AI models. https://www.edpb.europa.eu

Parlamento Europeo y Consejo de la Unión Europea. (2025). Reglamento (UE) 2025/327 relativo al Espacio Europeo de Datos Sanitarios. Diario Oficial de la Unión Europea, L 2025/327.

Reglamento (UE) 2024/1689 (AI Act). (2024). Diario Oficial de la Unión Europea, Artículo 6.

Reed Smith. (2025). The EU AI Act and medical devices: Navigating high-risk compliance.

Freyr Solutions. (2025). EU AI Act & high-risk AI in medical devices.

MDCG 2025-6. (2025). Interplay between the Medical Devices Regulation and the AI Act.

Hao, F., et al. (2025). AI Act compliance within the MyHealth@EU framework. JMIR, 27(1), e81184.

Fathima, A. Z., et al. (2024). Leveraging SHAP for interpretable diabetes prediction.

Shearer, C. (2000). The CRISP-DM model: The new blueprint for data mining. Journal of Data Warehousing, 5(4), 13-22.

Brownlee, M. (2005). The pathobiology of diabetic complications: A unifying mechanism. Diabetes, 54(6), 1615-1625. https://doi.org/10.2337/diabetes.54.6.1615

Abgrall, G., Holder, A. L., Chelly Dagdia, Z., & Zeitouni, K. (2024). Should AI models be explainable to clinicians? Critical Care, 28, 301. https://doi.org/10.1186/s13054-024-05005-y

Cheung, N., Mitchell, P., & Wong, T. Y. (2010). Diabetic retinopathy. The Lancet, 376(9735), 124-136. https://doi.org/10.1016/S0140-6736(09)62124-3

Alicic, R. Z., Rooney, M. T., & Tuttle, K. R. (2017). Diabetic kidney disease: Challenges, progress, and possibilities. Clinical Journal of the American Society of Nephrology, 12(12), 2032-2045. https://doi.org/10.2215/CJN.11491116

Feldman, E. L., Nave, K. A., Jensen, T. S., & Bennett, D. L. (2019). New horizons in diabetic neuropathy: Mechanisms, bioenergetics, and pain. Neuron, 93(6), 1296-1313. https://doi.org/10.1016/j.neuron.2017.02.005

11. Anexos

Anexo A: Enlace al repositorio de código

El código fuente completo del proyecto (notebooks de colab con el pipeline de datos, entrenamiento, evaluación y generación de visualizaciones) está disponible en el siguiente repositorio público:

https://colab.research.google.com/drive/1nxlBXogwB-f0mRqjxJQLHItSifH28d7w#scrollTo=JbVSXyW2fd-7